

Gabriel Lucas Silva Machado

Limiarização em redes neurais convolucionais para classificação em cenário aberto

Belo Horizonte

2018/2

Gabriel Lucas Silva Machado

Limiarização em redes neurais convolucionais para classificação em cenário aberto

Proposta de Pesquisa Científica para o trabalho da disciplina Projeto Orientado em Computação II do curso de Bacharelado em Ciência da Computação da UFMG

Univerisdade Federal de Minas Gerais - UFMG

Instituto de Ciências Exatas

Departamento de Ciência da Computação

Orientador: Jefersson Alex dos Santos

Belo Horizonte

2018/2

Agradecimentos

Os agradecimentos principais são direcionados aos alunos Caio Cesar Viana da Silva e Keiller Nogueira, que juntamente ao professor Jefersson Alex dos Santos me orientaram na elaboração desse projeto.

Sumário

1	Introdução	4
2	Referencial Teórico	5
3	Metodologia	6
4	Resultados Esperados	7
5	Etapas e Cronogramas	8
	Referências	9

1 Introdução

Os constantes avanços tecnológicos que ocorreram nos últimos anos proporcionaram ferramentas capazes de captar imagens de alta resolução da superfície terrestre através do uso de sensores (CAMPBELL; WYNNE, 2011), além de tecnologias capazes de processar essas imagens. O estudo de como coletar, armazenar e analisar essas imagens ficou conhecido como sensoriamento remoto.

A quantidade de informação que imagens de sensoriamento remoto carregam é imensa, e por causa disso, estas vem sendo utilizadas para diversos tipos de aplicações, tais como planejamento urbano (CHEN et al., 2006), agricultura (NOGUEIRA et al., 2016), prevenção de desastres naturais (NOGUEIRA et al., 2018), entre outras. Por causa dessa importância, surgiram diversas técnicas com objetivo de analisar, entender, ou até mesmo criar *insights* a partir dessas imagens. Nesse trabalho será usado uma dessas técnicas, sendo esta conhecida como redes neurais convolucionais (*CNN*).

Diferentemente de problemas *closed set*, nos quais todas as classes são conhecidas durante a fase de treinamento, problemas que utilizam imagens como *inputs*, normalmente são classificados como *open set*. Nessa abordagem, durante o treinamento são apresentadas informações incompletas das classes presentes no problema, e classes desconhecidas podem ser submetidas durante a fase de testes. (SCHEIRER et al., 2013) No caso desse trabalho, será utilizado uma abordagem simplificada do *open set*, em que todas as classes não relevantes ao problema serão colocadas em um único *cluster*.

As saídas geradas por redes neurais convolucionais, tipicamente passam por um algoritmo classificador. No caso desse trabalho, será utilizado um algoritmo baseado em uma regressão logística, que antes de retornar a saída passa por uma função conhecida *softmax*. Essa função retorna a probabilidade que uma dada entrada pertença a cada classe definida. Para aplicá-la em um problema de classificação binária (classe relevante e não relevante) é necessário definir um parâmetro conhecido como *threshold*, que representa a probabilidade que delimita a distinção dessas duas classes.

Tendo isso em mente, o objetivo desse trabalho consiste em avaliar experimentalmente formas para estimação de *thresholds* que otimizem as classificações feitas por uma *CNN open set*. Para essa tarefa, será utilizado uma rede neural convolucional com arquitetura definida em (NOGUEIRA et al., 2016), aplicada ao *dataset* de imagens de sensoriamento remoto *AGRICULTURE*¹, com o propósito de segmentar as regiões da imagem que contêm plantações de café.

¹ *Dataset* disponível para *download* em: <http://www.patreo.dcc.ufmg.br/2017/11/12/brazilian-coffee-scenes-dataset>

2 Referencial Teórico

Dois anos atrás, o trabalho conhecido como "*Learning to Semantically Segment High-Resolution Remote Sensing Images*" (NOGUEIRA et al., 2016) definiu duas arquiteturas para redes neurais convolucionais para realizar segmentação semântica em imagens de sensoriamento remoto, utilizando uma abordagem *pixel-wise*. Esse artigo é importante para esse trabalho, pois ele descreve arquiteturas de *CNNs* e técnicas fundamentais para o desenvolvimento desse projeto.

Também na mesma época, foi publicado o *paper* "*Towards Open Set Deep Networks*" (BENDALE; BOULT, 2015), que apresenta uma metodologia para adaptar redes neurais profundas à abordagem *open set*. Apesar da metodologia descrita no *paper* não ser utilizada nesse trabalho, ele é importante pela simples razão de se tratar de uma abordagem *open set*, que para o contexto de segmentação em imagens de sensoriamento remoto é de extrema relevância.

Em relação a implementação desse trabalho, será utilizado o *framework TensorFlow* (TENSORFLOW, 2018). Os motivos da escolha se devem principalmente pela excelente documentação e suporte da comunidade.

3 Metodologia

A metodologia do trabalho será dividida nas seguintes etapas:

1. **Implementação e treinamento da rede neural convolucional:** Nessa etapa será feito o tratamento inicial das imagens para que possam ser utilizadas na rede neural. Além disso, será implementada a arquitetura proposta no artigo ([NOGUEIRA et al., 2016](#)), e será realizado o treinamento dessa rede utilizando o *dataset AGRI-CULTURE*. É importante ressaltar que será utilizado o protocolo *K-Folds Cross Validation* ([BRONSHTEIN, 2017](#)) para validação do treinamento.
2. **Definição e implementação de métricas para estimar o *threshold*:** Nessa etapa serão estudadas formas de estimar o parâmetro *threshold* com o objetivo de maximizar a taxa de acerto das classificações feitas pela *CNN*. Após isso, será implementado alguma dessas formas.
3. **Avaliação de resultados e escrita do relatório final:** A etapa final do trabalho consiste em uma análise experimental do método implementado na etapa 2. A apresentação dos resultados obtidos será feita no relatório final.

4 Resultados Esperados

Como especificado anteriormente, esse trabalho consiste na implementação da rede neural proposta em (NOGUEIRA et al., 2016) para resolver o problema de segmentação de plantações de café a partir do *dataset AGRICULTURE*¹ (PENATTI; NOGUEIRA; SANTOS, 2015).

Diferentemente da implementação feita em (NOGUEIRA et al., 2016), esta se diferenciara por se tratar de uma abordagem *open set* simples com o uso de *threshold*. O objetivo final da pesquisa é determinar uma boa metodologia para estimar o valor ótimo para o *threshold*.

Em relação aos resultados, espera-se que com esse trabalho seja possível melhorar os resultados obtidos com uma abordagem *closed set*, e que seja possível definir uma boa metodologia para o cálculo do valor ótimo para o *threshold*.

¹ *Dataset* disponível para *download* em: <http://www.patreo.dcc.ufmg.br/2017/11/12/brazilian-coffee-scenes-dataset>

5 Etapas e Cronogramas

Referências

BENDALE, A.; BOULT, T. E. Towards open set deep networks. *CoRR*, abs/1511.06233, 2015. Disponível em: <<http://arxiv.org/abs/1511.06233>>. Citado na página 5.

BRONSHTEIN, A. *Data Science*. 2017. Disponível em: <<https://towardsdatascience.com/train-test-split-and-cross-validation-in-python-80b61beca4b6>>. Citado na página 6.

CAMPBELL, J.; WYNNE, R. *Introduction to Remote Sensing*. Guilford Publications, 2011. ISBN 9781609181765. Disponível em: <<https://books.google.com.br/books?id=zgQDZEya6foC>>. Citado na página 4.

CHEN, X.-L. et al. Remote sensing image-based analysis of the relationship between urban heat island and land use/cover changes. *Remote Sensing of Environment*, v. 104, n. 2, p. 133 – 146, 2006. ISSN 0034-4257. Thermal Remote Sensing of Urban Areas. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0034425706001787>>. Citado na página 4.

NOGUEIRA, K. et al. Exploiting convnet diversity for flooding identification. *IEEE Geoscience and Remote Sensing Letters*, v. 15, n. 9, p. 1446–1450, Sept 2018. ISSN 1545-598X. Citado na página 4.

NOGUEIRA, K. et al. Learning to semantically segment high-resolution remote sensing images. In: *2016 23rd International Conference on Pattern Recognition (ICPR)*. [S.l.: s.n.], 2016. p. 3566–3571. Citado 5 vezes nas páginas 4, 5, 6, 7 e 8.

PENATTI, O. A. B.; NOGUEIRA, K.; SANTOS, J. A. dos. Do deep features generalize from everyday objects to remote sensing and aerial scenes domains? In: *2015 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. [S.l.: s.n.], 2015. p. 44–51. ISSN 2160-7516. Citado na página 7.

SCHEIRER, W. J. et al. Toward open set recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 35, n. 7, p. 1757–1772, July 2013. ISSN 0162-8828. Citado na página 4.

TENSORFLOW. 2018. Disponível em: <<https://www.tensorflow.org/>>. Citado na página 5.